AI WEB 网页开发挑战赛 · 作品技术报告

图证

图表证据审计台

从一张截图，走到一条
有计算、有来源、可复查的结论。

多模态读取　受限工具调查　引用与口径校验

一个看起来相同、含义却不同的数字

同值 ≠ 同口径

同比与环比、不同月份、不同范围，
不能因为数字相等就视为同一条证据。

图证让 AI 找出需要核查的主张，由程序校验依据与计算。

22
固定开发评测题
两臂、每题三次

12
独立冻结预留题
离线机制已验证，正式盲审待完成

6:38
新版实机画面母版
1080p，待普通话配音

岭南凤翔团队 · C组 · 梁钦健 / 梁智量
岭南职业技术学院（清远校区）
Vue 3 · TypeScript · Node.js / Express · Windows 本机 Web 应用
材料整理：2026-10-23 · 产品代码参考：78ca62a（另含本轮材料工具与文档更新）

文档整理新增模型请求为 0；新版实录另有独立官方请求。历史整组评测、离线验证与演示分别统计。图内一致只说明截图自洽，来源一致只说明与所引发布一致。

更新 / 2026-10-23

当前交付与验证边界

当前界面为暖纸色与靛蓝，覆盖首页、来源核验、图内工作台和模型设置。下文保留原技术方案和注明日期的历史评测；旧界面图用于说明流程，当前外观以下图及新版实录为准。



当前首页静态截图。示例卡明确是预览，不是一次模型运行结果。

交付	实际结果	边界
新版实机视频	398.233 秒、1920×1080、30 fps，无音轨；附九段配音区间及讲稿	普通话配音、混音和最终人工走查待用户完成
本批真实模型	DeepSeek 官方 deepseek-flash，7 次模型 HTTP；输入 9,190 / 输出 2,649 tokens	是产品路径演示，不是独立盲审或稳定性结果；余额差额不作为逐笔收费
主线离线交付	2026-10-18 归档：445 项单元/API、140 项浏览器通过/1 项不适用跳过、四组配置端口通过	假密钥/替身不当作真实模型或另一台 Windows 验收
独立预留包	12 题及三臂执行、候选锁、预算与逐请求记录机制已实现	正式完整运行及负责人抽查尚未完成；历史探索失败、未知用量及待办保留

实录展示 80→100 的 25% 计算、更正为 96 后的 20%、CPI 环比 0.8% 与所引发布 0.2% 的不一致、引用、工具轨迹及采用建议后旧结果失效。缺口径案例本次没有触发追问或执行恢复，保留待核对；格式恢复只到合法图片输入。

2026-10-23 用户提供团队信息并授权仓库公开，未登录访问已验证；本轮视频延期。当前材料及独立待办见 docs/submission/README.md；原片及请求证据：[E8]；UI 主线交付：[E9]。本机检查不代替第二台 Windows、负责人签字或平台回执。

让每个结论都能复查

图证面向只有图表截图的普通读者，分别检查图内计算和公开来源，说明每条结论依据什么、适用于什么范围。

只有截图
模型抄录图上数字，读者确认或更正，程序计算涨幅、核对跨图口径，并提示纵轴呈现风险。

具有可查来源
逐条对照固定官方资料库核验图文主张，保留检索、推断检查、关键补证及修改建议的过程与引用。

评审阅读导航

项目概述与需求	**3-4**	系统架构	**5**
AI 选型与结构化读取	**6**	工具调查与检索校验	**7-8**
核心案例与人机协作	**9-11**	前端工程与交互	**12**
评测设计与实际结果	**13-14**	测试、运行与部署	**15**
创新、局限与展望	**16**	证据与复现索引	**17**

与官网评分维度的对应

维度 / 权重	本报告展示的核心内容	页码
AI 技术深度 / 35%	多模态结构化输出、模型自选工具、检索增益、引用与改写校验	6-11、13-14
创新性 / 25%	结论按证据分级，必要补证与失效机制，官方修订贯通建议	4、9-11、16
前端工程质量 / 10%	类型约束、按路由拆包、请求隔离、三视口自动化	5、12、15
实用性 / 10%	从算术矛盾到同比 / 环比误读的可操作案例	4、9-11
用户体验 / 10%	逐条确认、补证说明、历史结论、失败恢复	10、12
社会价值与商业潜力 / 10%	数据素养与信息阅读场景；应用方向与验证条件	16

评分权重于 2026-10-23 重新读取官网赛道详情核实。这里只映射材料与评分项，不预测赛事得分。

先回答读者能核查什么

读者通常拿不到原始表格。直接让大模型判断“真假”，容易在标签看不清、口径缺失或只有模型记忆时给出确定结论。图证因此逐步展示判断所需的依据。

用户需要	产品行为	验收观察点
核对标题涨幅	确认图上两值后用程序复算	80 → 100 得到 25%，与标题 40% 矛盾
比较两张图	逐项核对指标、范围、时间、单位	口径不一致时先提示冲突
理解纵轴风险	并列原轴与从零起点的柱高对照	提示视觉风险，不将其直接判为造假
核查配文依据	拆解主张并检索适用官方发布	错月份、错范围及术语页引用不被当作数值依据
补足关键口径	只问会改变结论的一个问题	用户补充与官方依据分别标识
修改错误配文	逐处给出有引用的建议，由用户采用	输入改动后旧建议立即失效

图内审计的完整路径

图片 / 样例 → 模型观察 → 人工确认 → 确定性计算 → 证据卡。

增长率公式

(100 - 80) / 80 × 100 = 25%

标题声称 40%，相差 15 个百分点。

数值不清、单位不一致、时间顺序错误或基数为零时，保持“需要确认”。用户更正读数后重新计算，原始模型观察仍可复查。

预置样例与实时模型读取在页面上分别标注；离线样例可复现计算，但不证明模型读图质量。



图 1 · 逐条确认与证据卡。预置样例界面截图，不是实时模型输出。

实现：shared/audit.ts、shared/cross-image.ts、shared/axis-risk.ts；验证：tests/audit.test.ts、tests/cross-image.test.ts、e2e/reader-workbench.spec.ts。[E1]

模型负责理解，程序负责校验

模型接口负责多模态理解和语言判断；领域层负责计算、引用、口径校验及输入版本绑定，便于重复测试。

浏览器 • Vue 3
图片与配文输入 / 逐条确认 / 证据卡 / 工具轨迹 / 历史结果 / 模型设置

↓ HTTP / 本机 API ↑

本机服务 • Express + TypeScript
图片格式与大小验证 / 模型协议适配 / 调查循环 / 会话恢复 / 设置存储

↓ 结构化观察与工具结果 ↑

共享领域逻辑 • shared/
增长率 / 跨图口径 / 纵轴风险 / 固定资料库检索 / 来源适用性 / 修改建议校验

接口	输入与输出	作用
VisionAdapter	图片 → 观察值、模型与读取追踪	页面与领域计算不依赖具体模型厂商
SourceInvestigationDriver	start / continue / resume / finalize	双协议共用调查编排与判定规则
SourceSessionStore	调查 ID、输入指纹、驱动器与既有结果	恢复同一调查，防止并发消费或错图接续

数据从哪里来，保留在哪里

图片与配文：上传图片先进入服务端内存，调用模型时发送给已配置的远程服务。可恢复对话可在本机内存保留至过期或淘汰。

调查会话：最多保留 16 条，默认有效期 30 分钟；图片与配文的 SHA-256 指纹约束恢复请求。

公开资料：五条国家统计局材料随代码保存，包含链接、发布日期、摘录与内容指纹；运行时只检索此固定集合。

密钥：设置页提交给回环 API，保存在当前 Windows 用户配置目录；页面只接收“是否已配置”。

本机存储不代表所有数据都留在本机：上传图文会发送给用户选择的模型提供方；可恢复对话也不是在请求结束时立即清空。

代码：server/app.ts、server/source-sessions.ts、server/model-settings.ts；领域与接口职责见 docs/STRUCTURE.md、CONTEXT.md。[E1]

把可变输出收敛为可检查结构

模型与协议的选择

选择	理由与集成方式	验证边界
云端多模态模型	读取截图中的文字、数值与主张，同时理解配文，避免另建 OCR 与语言分析两条分离路径	模糊标签仍需人工确认；不是像素级自动测量工具
Anthropic Messages	使用 image + text 输入、tool_use / tool_result 对话，来源调查实测采用 deepseek-flash 兼容端点	既有来源调查的整组在线证据对应此协议与模型
OpenAI Responses	视觉读取用 JSON Schema；来源调查用 function calling，统一映射到共享驱动器接口	视觉路径有历史在线记录；工具调查仅有本地替身证据
可配置提供方	协议、地址、型号和密钥分别保存，预设区分在线实测与文档依据	预设存在或连接成功，不证明图片与完整工具循环可用

提示词与输出约束

逐字抄录
不补图上没有的信息

主张拆解
原句与图上摘录分开

类型标记
陈述 / 推断 / 观点

字段校验
Zod 与来源规则

主张结构示意

```
{ claimText, fromImage, imageExcerpt,
  kind, metric, period, scope, basis, value, direction }
```

保留原文；缺失字段保持空值；
比较方式不明确时不从数值相等反推口径。

直接陈述可以对照同口径数值。推断需要单独检查所需比较方式与方向，例如“同比涨幅回落”不能直接推出“比上月便宜”。观点、动机或未来预测显示为不支持核验。

兼容与失败处理

模型返回结构错误时，调查汇总可获得一次带具体字段错误的重报机会；仍不合法则如实停止。图片读取超时、上游失败和无效结构有独立错误提示，不填入猜测值或预置结果。

工程优化针对可观察行为：结构化输出约束格式，原文追溯限制信息补全，确定性计算降低算术漂移，引用校验限制证据使用；模型兼容回退与重报仍可能产生额外请求。

server/vision-prompt.ts、server/vision-schema.ts、server/observation.ts、server/source-prompt.ts；协议实测见 [E2]、[E5]。

行动可选择，执行有边界

模型根据图文选择检索、比较、追问或汇总。服务端逐个校验工具及参数，执行后将结果返回模型，再按规定的结构整理结论。

图文输入 → 模型选择工具 → 服务端校验执行 → 结果回送 / 汇总

工具	职责	服务端限制
search_source_library	按指标、月份、范围与关键词检索	只读固定集合；结果标注适用与排除原因
compare_values	比较有限数值、返回差值	程序确定性计算，拒绝无效参数
request_clarification	指出缺少哪一项口径、影响哪条主张	最多一次；补充标为“用户提供”
report_source_finding	提交主张、引用、未解决项与改写提议	按 schema 接收，引用与结论由程序再校验

3 次 / 轮
检索、比较、追问
总计最多 6 次

4 个工具轮
强制汇总与结构修复
可能增加模型轮次

150 秒检查阈值
循环边界检查
单个模型请求超时 60 秒

上述工具预算不包含汇总调用，也不等于最多六次模型 HTTP 请求。150 秒是循环停止检查阈值，不能当作所有在途请求的严格总耗时上限。



图 2 · 每次调用展示工具、简短行动理由、输入摘要、状态与耗时。替身响应界面截图；真实调用轨迹见逐次 JSON。[E3]

未知工具、超预算调用与“工具结果还未返回就汇总”会被拒绝并记录。补证恢复继承既有调用数与工具轮预算，不通过恢复重新获得额度。

server/source-investigation.ts、server/source-tools.ts、shared/source-audit.ts；tests/source-investigation.test.ts 覆盖预算、无检索、恢复与非法汇总。[E1]

命中资料，还要匹配口径

检索增强工作流只使用固定领域资料：先按指标与别名筛选，再按月份、范围和词项匹配排序，同时说明命中材料是否适用。五条材料适合用确定性规则检索，无需引入向量数据库。

资料	用途	不能支持什么
2025-12 CPI 发布	全国同比 0.8%、环比 0.2%	其他月份、城市范围的主张
同比 / 环比解释页	解释比较方式	任何具体月份的数值结论
2026-08 CPI 发布	同比同为 0.8%、环比 0.4%；验证错月份干扰	用“同值”替代时间匹配
零售总额 2026-08-17 发布	逐月环比表中的旧值	无视后续官方修订的最终值
零售总额 2026-09-15 发布	官方修订声明与更新后的逐月环比值	没有修订声明的跨来源争议

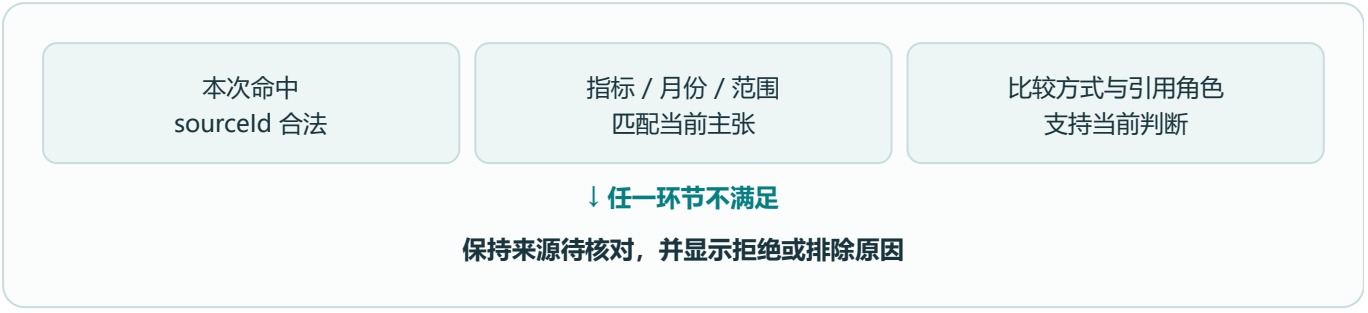




图 3 · 固定官方资料库显示发布者、链接、发布日期与口径。界面展示截图，不是运行时抓取页面。

可复查的来源记录

每条记录保存短摘录、数值与适用月份；FNV-1a 内容指纹发现集合内容变动，但不是防篡改签名。模型只能引用本次命中的 ID，术语、背景与数值依据分开显示。

能力范围限于固定资料，未实现开放搜索、向量索引或 MCP 服务。

shared/source-library.ts、shared/source-audit.ts；资料原始页面 [S1]-[S5]，评测原始记录 [E3]。

同样的 0.8%，不是同样的结论

输入团队自制 CPI 图，配文写“比上月上涨 0.8%”。模型需要分开识别图上读数与配文的比较方式，再检索适用来源。



图 4 · 团队自制样例，依据公开数值绘制；不是国家统计局原图。其缺失的比较方式不能由 AI 猜补。

配文主张

“比上月上涨 0.8%” → 比较方式是环比。

适用来源

2025 年 12 月官方发布：同比 0.8%，环比 0.2%。

与所引来源不一致

0.8% - 0.2% = 0.6 个百分点

只说明配文与此发布不一致，不评价作者动机。

检查对象	程序处理	用户看到什么
配文的环比主张	匹配 2025-12、全国、CPI、环比	不一致、正确值 0.2% 与引用
图上缺比较方式的数值	不能从同值推断同比	来源待核对、缺失口径说明
2026-08 同比 0.8% 的命中	与当前主张月份不一致	排除原因，不用作当前数值依据
配文明确写 2026-08 环比	按配文自己的月份重新匹配	与该月环比 0.4% 核对，不沿用图上的月份



图 5 · 主张逐条展示结论、原文与依据。替身响应界面截图；真实案例 q04 / q05 的逐次结果见 [E3]、[E4]。

案例 q04 / q05；samples/source-audit-questions.json、samples/source-audit-expectations.json。最新整组记录 q05 三次均按 2026-08 得到配文不一致。[E3]

让用户补口径，让证据约束改写

配文仅写“12 月 CPI 上涨 0.8%”时，同值不足以确定同比还是环比。先检索资料，再询问缺少的比较方式；回答以“用户提供”进入当前主张。

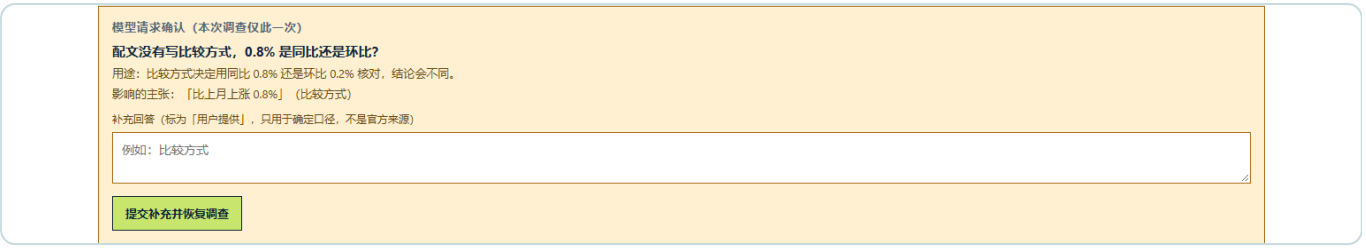


图 6 · 问题说明答案影响哪条主张。替身响应界面截图。

补证沿同一个调查 ID 和模型对话恢复，继承既有检索命中与预算。回答不能覆盖图文已明确写出的口径；冲突或无法解析时保留待核对。

每处修改都有依据

原结论	建议处理	校验依据
与来源一致	保留原句	不因为模型换说法而新增事实
与来源不一致	替换为适用来源中的正确值 / 方向	数值、月份、范围与当前引用
待核对 / 推断依据不足	保留限定或建议删除	不把未解决项写成已证实



图 7 · 原句、建议、理由与引用并列，用户显式采用。替身响应界面截图。

模型提出建议后，程序逐处验证；未通过的提议保留拒绝原因，并改用程序的备用结果。用户采用后才写入配文，旧结论转入历史；更换输入或重新调查会使旧建议失效。

实现：shared/source-audit.ts、server/source-sessions.ts；q18 / q20 在线记录 [E3][E4][E6]，页面测试 [E1]。

依据变了，结论和建议一起更新

“社会消费品零售总额”的两份官方发布带有明确修订声明。系统据此识别旧发布被替代的逐月环比值，保存修订前后值与两份发布链接。

旧发布	官方修订声明	有效依据
2026-08-17 2026-06 环比 0.35%	2026-09-15 发布 建立明确替代关系	2026-06 环比 0.40% 用于结论与修改建议

案例	依据处理与结果	历史实测
q21 配文使用旧值	按修订后 0.40% 核对，旧值 0.35% 判为不一致	检索臂 3/3 通过
q22 配文使用修订后值	配文与来源一致；图中旧值仍不一致	检索臂 3/3 通过

5 次运行发生版本替代，5 次通过判定
按运行计数，不按主张计数。复查由程序同步完成，不新增模型调用、不增加检索轮次；不声称程序计算本身耗时为零。

仅有数值差异、没有官方修订声明时，不能使用这条规则。现有能力覆盖官方声明明确的替代关系；“同口径来源存在分歧”尚无实现与验收证据。

输入改变时怎样阻止旧结论复活

当前输入 A 得到结论 A	修改图 / 配文 请求序号失效	旧结果转历史 迟到响应丢弃	重新核验 B 建立新依据



图 8 · 历史结论注明失效原因，仅作复查。替身响应界面截图。

服务端恢复时检查图片字节与配文指纹，拒绝过期、错输入和并发恢复；前端 AbortController 与请求序号一起阻止迟到结果覆盖新输入。浏览器取消不等于已发送的上游调用立即停止计费。

资料 [S4]-[S5]；版本复查记录 [E3]，本地引用贯通验证 [E1]。本地修复之后尚未重新在线验证。[E7]

长耗时 AI 任务也要可操作

清晰的任务页面

首页、图内工作台、来源核验和设置页各有明确职责。按路由懒加载；共享证据卡组件与 TypeScript 领域结果减少前后端语义偏差。

防止半完成状态

读取图片前清除旧结论；取消、换图、框选和离页会使在途结果失效。主图载入期间禁用跨图选择并说明原因，完成或失败后恢复操作。

面向复查的层级

先展示当前状态，再展开主张原文、依据、排除资料和调用轨迹；超出核验上限的原文单独列出，避免读者以为全文都已核查。

加载与错误反馈

显示等待时间、取消入口与分类错误，提供配置、重试、缩图和框选路径。当前轨迹在调查返回后展示，尚未实现 SSE 流式工具事件。

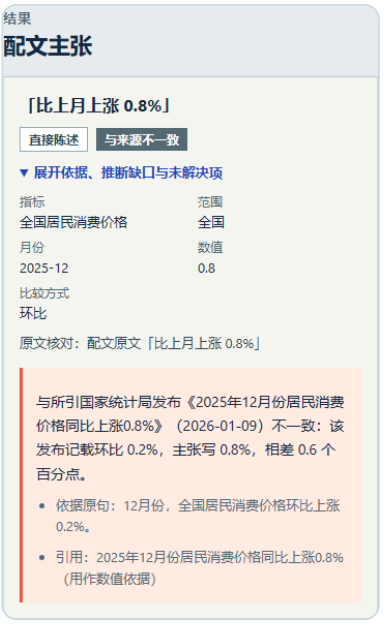


图 9 · 390px 视口的主张卡。替身响应界面截图。

工程证据	本次结果	证明范围
三视口端到端	30 用例 ×3 视口 = 90/90	320、390、1280px 的路径、竞态与溢出检查
类型检查与构建	Vue、服务端、e2e 配置均通过	本地类型与打包成功
前端构建产物	主 JS gzip 37.43 kB；样式 gzip 13.23 kB	资源体积；不等于首屏速度或 Core Web Vitals

界面路径自动化采用预置数据和替身响应。它证明交互与状态处理，不能代替真实模型体验、辅助技术测试或陌生用户可用性研究。

web/router.ts、web/pages/、web/components/；三视口测试 [E1]。本次构建记录与评估见 [E7]。

检索有没有用，要保留对照

两臂使用相同的模型、图片、配文、参数和预算，只改变检索工具是否可用及相应的必要说明，再按独立期望判定每次运行。

有检索臂
模型可搜索固定资料库，引用本次命中材料，并接受程序口径校验。

无检索臂
不声明检索工具，拒绝检索请求；命中集合为空，不允许用模型记忆替代来源。

控制项	设计
模型与协议	deepseek-flash；Anthropic Messages 兼容端点
题集	22 道团队自制开发题，每题每臂三次；含错数值、错月份、错范围、推断、观点、补证与版本修订
独立期望	题目与期望分文件保存；运行前核对图片、资料库指纹与预算冻结配置
恢复段	只有模型提出追问时才运行，初查与恢复分别判定；缺追问不伪造恢复记录
失败记录	上游或结构失败单列，不用样例顶替，不从数据集中删除
建议判定	独立复算数值、月份、范围、加强表述及未解决项限定规则

指标的准确含义

```
运行通过率 = judgment.ok 为 true 的有效运行数
             / status 为 ok 的有效运行数

一次运行可能包含多个主张，
判定同时涉及状态、引用、追问、补证或建议要求。
```

旧记录将此指标称为“主张状态正确率”。按评测实现，它是**整次运行通过率**，不是逐条主张准确率；本报告据此统一表述，保留原始数据。

无检索臂受同样的“有依据才能下结论”规则约束。因此对照说明来源支撑工作流的价值，不能声称相对普通聊天模型提升了通用事实判断准确率。题集均为开发题，尚无独立预留集。

samples/source-audit-questions.json、samples/source-audit-expectations.json；scripts/evaluate-source-audit.ts 的 judgeRun / summarizeEvaluation。[E3]

展示结果，也保留失败

最新存档整组评测：22 题 ×2 臂 ×3 次，外加条件触发的补证恢复段。计划最多 138 次，实际记录 137 次；模型没有追问的一次恢复未发生。



指标	有检索	无检索
有效运行 / 通过运行	68 / 61	69 / 19
上游 / 结构失败	0	0
接受引用 / 被拒引用	145 / 2	0 / 0
虚构引用 / 无适用来源越界	0 / 0	0 / 0
平均耗时	6,723 ms	5,472 ms

两臂汇总结果相差约 62.2 个百分点；由于触发恢复的条件不同，分母也不同。零违规只是在这组有限题目中观察到的结果，不能保证所有输入都安全。[E3]

检索臂的七次未通过

题型	未通过数	实际问题
q06 范围错配	2	未产出可匹配的配文主张，含无结论运行
q16 超过三条	1	整轮无结论
q18 补证恢复	3	追问漂移、未套用用户补充等
q20 混合改写	1	建议数值不满足期望

此前 20 题版本为 58/62（93.5%）；题集、资料库和运行轮次不同，不能合并成一个准确率，也不能仅凭下降推断新增功能导致退化。五道演示题的一次抽样为 6/6，仅说明该次配置下通过。[E4][E6]

这些在线记录早于后续来源引用、方向改写与补证隔离修复。当前代码已通过本地回归；修复后的真实模型稳定性尚未复验。[E7]

本次按原始 JSON 重新汇总 137 条记录，结果与分臂分母、通过数及平均耗时相符。[E3]

可复现的本机 Web 应用

归档本地验证（2026-10-01）

检查	结果	证明范围
npm test	361/361，21 个文件	行为、API、结构与边界回归；不调用真实模型
npm run test:e2e	90/90，30 用例 ×3 视口	替身 / 预置数据下的浏览器路径
npm run build	通过	Web、服务端与 e2e 类型检查及产物构建
npm run eval:samples	23/23	18 张固定图与五组跨图的独立期望
npm run verify:sample-renders	18/18	本机 Edge 下 SVG 与 PNG 字节同源
npm run docs:check	无缺失链接	本地文件链接存在；不验证网络与内容

评审复现方式

```
# Windows, Node 22.12+ 的 22.x 或 24.x, Edge
npm ci
npm run dev
# 网页 http://127.0.0.1:5173
# API  http://127.0.0.1:3001
```

网页与 API 端口在 `.env` 配置（WEB_PORT、PORT）。启动先预检端口，被占用时直接提示；不静默更换端口。模型配置默认使用本机设置页，也支持显式启用完整服务端环境配置；离线样例、计算和固定样例评测不需要密钥。

CI 与部署状态

GitHub Actions 使用 Windows + Node 24，执行文档链接、类型、构建、行为测试和三视口浏览器测试；失败上传 trace。图片字节同源步骤受 Edge 栅格化差异影响，属于允许失败的信号，不能由 CI 总绿推断其通过。

目前只验证了本机运行。公网部署尚无上线或可用性证据，现有反向代理方案也未证明已部署。公共演示是赛事可选项，需另行处理访问、密钥隔离及额度管理。

2026-10-02 环境密钥兼容（本地工作区补充）
显式设置 MODEL_CONFIG_SOURCE=env，服务端一次完整读取 MODEL_PROVIDER、MODEL_BASE_URL、MODEL_NAME、MODEL_API_KEY。缺项或非法地址明确失败，不混用本机文件。环境密钥不写回、不回传、不进日志，设置页显示来源并只读。默认 file 模式保持本机设置。临时配置与假密钥下两种来源、默认 / 自定义端口及 Vite 代理通过；本轮 0 次真实模型调用，未证明在线调用或服务器部署。

本地命令、基线与 GitHub CI 核对见 [E7]；配置规则 docs/MODEL-CONFIG.md；离线验收 docs/evidence/model-config-env-2026-10-02.md；官网 [R1]。

把 AI 的判断变成有依据的操作

创新点	用户获得的价值	工程落点
按证据分级的图表阅读	知道哪一部分能核查，哪一部分仍不确定	图内、来源、推断与观点分别判定
受控的模型调查	可查看行动理由、工具结果和停止原因	共享编排器、参数校验与调用预算
有来源的局部改写	知道改哪里、为什么改、依据在哪里	原句与引用绑定，提议逐处验证
补证与输入失效联动	旧判断不会伪装成新输入的结果	用户补充标记、指纹、请求序号与历史区
官方版本替代贯通	复查旧数值，同时保持结论与建议依据一致	明确修订声明、有效来源与版本记录

社会价值与应用方向

图证把算术、统计口径及来源辨识放进读图操作中，可用于数据素养教学、资讯阅读和编辑自查。后续可尝试教学案例工具或编辑辅助模块；目前没有付费用户、市场规模或节省时间的实测，尚不能证明商业模式成立。

已经知道的局限

- 资料库只有五条材料、两类指标。除 22 道开发题外，已有 12 道独立冻结预留题及离线三臂机制；正式完整评测和负责人盲审仍未完成。
- 主张分类、追问时机和改写仍有模型漂移；固定词表与数值规则无法覆盖全部语言表达。
- 来源一致不是事实真实性保证；同口径来源分歧、开放检索与通用知识库尚未实现。
- 完整工具循环在线证据只覆盖指定 Messages 配置；换协议、端点或模型需重新验证。
- 没有真实用户可用性研究、生产部署压测或长期可用性承诺；实时工具流式展示尚未实现。

总结与下一步

当前已实现截图确认、工具检索、引用核对、必要补证及修改建议的完整流程。下一步应先处理旧请求的未知状态，再用已冻结的预留题对新候选进行正式三臂评测和负责人抽查，之后按适用场景扩展资料库。用户研究和公共演示仍需各自实测通过才能算完成。

核心成果
AI 将图文转换成可调查的主张；程序把来源、口径和计算组合为可复查结论；用户决定是否补充与采用修改。

能力与验证范围交叉核对 PLAN.md、CONTEXT.md、docs/PHASES.md、代码、测试及 [E1]-[E7]。创新点描述产品机制，不声称算法首创。

附录 / 证据与复现索引

每个数字都有出处

在线数据采用仓库原始记录，指标口径按评测实现说明；本次材料核查不新增模型请求。截图用于展示界面，图注区分预置、替身与资料库展示。

编号	材料 / 入口	对应内容
E1	npm 脚本、tests/、e2e/	本地行为、API 与三视口浏览器验证
E2	模型协议在线记录	连接、图片读取、结构漂移与超时的历史证据
E3	22 题整组说明 / 原始 JSON	137 条记录；检索 61/68、无检索 19/69；版本替代 5 次
E4	20 题改写评测 / 原始 JSON	58/62；73 条模型提议中 31 采用、42 拒绝；124 次有效运行的独立不变量复算
E5	单图视觉记录、跨图在线记录	视觉路径的历史验收；与工具循环分开计数
E6	五题演示路径抽样	检索臂一次抽样 6/6，不代替整组或当前版本复验
E7	2026-10-01 项目评估	归档本地 361/361、90/90；按当时基线解释
E8	新版实录与配音 / 请求核对	398.233 秒无声实录、7 次真实模型 HTTP；配音及最终走查待办
E9	2026-10-18 UI 主线交付	离线 445 项单元/API、140 项浏览器通过/1 项跳过；不证明真实用户收益
R1	官网赛道详情 / 2026-10-23 核对记录	评分权重、PDF ≤30 页、视频 5-8 分钟 / 1080p 及普通话讲解、评审访问与密钥配置要求

固定官方资料的原始链接

编号	发布	引用入口
S1	2025 年 12 月 CPI	国家统计局 · 2026-01-09
S2	同比与环比解释	国家统计局 · 术语说明
S3	2026 年 8 月 CPI	国家统计局 · 2026-09-09
S4 / S5	零售总额旧发布与修订发布	国家统计局 · 2026-08-17 / 2026-09-15

资料录入包含原始链接、发布者、日期、短摘录、适用口径与指纹。本次未重新核对五条统计发布的完整页面，不把文件链接存在等同于来源再次验收。

源码与完整证据：github.com/Iskuyal/tuzheng。复现配置与安装步骤见仓库 README；赛事版生成命令为 `node docs/submission/build-report.mjs --competition`。

本文不包含密钥、真实用户数据、任务日志或开发待办。团队报名信息与视频、仓库访问权限在提交材料入口核对，不能由本 PDF 生成结果代替。