AI-WEB 网页开发挑战赛 · 省赛作品技术报告

图证

让只有截图的读者，能复查一张图表说的到底是不是图上和公开来源里有的东西

作品形态：Windows 本机运行的 Web 应用（Vue 3 + Node/Express + TypeScript），配固定资料库的受限工具循环

报告内容：需求分析、系统架构、AI 技术方案、核心功能实现、测试与部署、实际验证范围、创新点与局限

材料版本：2026-09-30（生成本 PDF 时的仓库基线 `b4f6e83`；本任务只新增文档、截图脚本与材料索引，未改动产品代码）

配套材料：演示视频（5—8 分钟 MP4，1080p）与代码仓库 README 的「提交材料索引」一节

团队信息：按赛事报名信息填写（见 README「团队信息」一节与本报告附录 B）

> **阅读前请先看这一条。**本报告把「本地测试通过」「真实模型在线验证」「尚未验证」分开标注。所有在线数字都引用仓库内 `docs/evidence/` 的逐次运行记录，并写明重复次数、波动区间与失败运行数；报告中的界面截图由替身响应渲染（脚本 `e2e/submission-screenshots.mjs`，不调用真实模型），真实模型输出以证据记录为准。

目录

页码为 PDF 实际页码。各章末尾的「证据出处」列出一句话结论能指到的命令或文件。

一	项目概述：问题、用户与边界	定位与一句话能力声明	3
二	需求分析	用户故事到能力的映射	5
三	系统架构设计	三层结构、两个窄接口、数据边界	7
四	AI 技术方案	选型理由、集成方式、受限工具循环与程序把关	9
五	核心功能实现	从图内审计到来源核验与修改建议	12
六	测试与部署	五层测试、配对评测方法、运行与 CI	16
七	实际验证范围	逐项标注本地 / 在线 / 未验证	18
八	创新点	技术创新的五处与对应的证据	21
九	总结与展望	已做到的、做不到的、下一步	22
附 A	证据索引	每个数字的命令或文件出处	23
附 B	材料纪律与敏感信息声明	真实 / 替身 / 预置分开计数	25

本报告怎么读

- **只想知道做了什么**：读第一章与第七章的两张表。
- **关心 AI 怎么做**：读第四章（工具循环、程序把关、优化策略）与第五章的来源核验一节。
- **要复现**：读第六章与 README 的「Windows 快速开始」「本地验证」，先跑不花钱的离线命令，再决定是否配置模型密钥。
- **要核对数字**：附录 A 给出每个数字的命令或证据文件；本报告不出现无法指认出处的数字。

一、项目概述

1.1 问题

社交平台和资讯站点上大量图表以截图形式传播。读者往往只有一张图，配文写在标题或正文里，出处要么没有，要么是一句「据国家统计局」。 读者要判断的其实是很朴素的两件事：**图里写的东西自己是否自洽**（例如柱高对应的涨幅和标题里的百分比对不对得上），以及 **配文说的和图上、和可查的公开来源是否一致**。这两件事目前都靠人肉：自己算一遍百分比，再去搜索官方发布核对口径。

更麻烦的是第二件事很容易做错。同一张 CPI 图，同比和环比可以是两个完全不同的数字；「上涨 0.8%」在 2025 年 12 月和 2026 年 8 月两个发布里同时存在，只看数值相等就下结论会得到相反的答案。普通读者既没有资料库，也没有逐条记录推理过程的工具。

1.2 目标用户

第一目标用户是只有截图的普通读者：他拿不到原始数据，也不打算做专业查证，只想知道这张图「能不能信、能信到什么程度、哪里需要打问号」。 这个定位决定了产品的三条底线：

- **只检查有依据的部分。**图上读不到、资料库没有的内容，一律给「需要确认 / 待核对」，不猜、不补。
- **结论不越权。**图内一致不代表现实数据真实；来源结论只说明「与所引发布是否一致」，不判断造假或作者动机。
- **过程可复查。**每条结论都要能点回到图上的抄录、模型读到的原文、程序算出的差值和所引用的公开材料。

1.3 产品形态与已完成的路径

应用在本机运行：`npm run dev` 同时启动页面与 API，浏览器打开 `http://127.0.0.1:5173`。四个页面：着陆页、审计工作台、来源核验、模型设置。

图内审计（阶段一—阶段三）	上传或选用团队自制样例 → 模型读出图上原文与数值 → 用户逐条确认 / 更正 → 程序按公式计算增长率并判定「图内一致 / 图内矛盾 / 需要确认」；可放入第二张图做跨图口径比对，可对柱状图给出纵轴不从零的呈现风险提示。
来源核验（阶段四，本次主演示路径）	上传图文 → 模型拆解主张（直接陈述 / 可检查推断 / 观点）→ 在固定国家统计局资料库里多轮调用受限工具检索与比较 → 程序校验引用与口径后给出逐条结论 → 缺关键口径时向用户提出一个具体问题 → 用户补充后沿同一条调查记录恢复 → 给出逐处有据的修改建议，由用户决定是否采用。
失败恢复（阶段五）	区分未配置密钥、上游失败、超时、结构错误与格式不支持；失败时不展示任何旧结论或预置结果，给出可操作的下一步。

1.4 本报告不声称的能力

以下能力未实现或未验收，本报告与演示视频都不作为能力声明：

- 固定资料库内的**「同口径冲突 → 来源存在分歧」**（两份同口径发布数值不同、且无法用修订声明消解）——本轮在国家统计局公开发布里没有找到任何一对可核对的分歧材料，按纪律不做没有实测支撑的能力声明。**版本修订 / 版本替代**已实现并实测，见 7.1。
- **开放网络检索 / 通用 RAG / 任意网页抓取**——运行时只查构建期写死的五条材料（CPI 三条 + 社会消费品零售总额两条），不访问开放网络。
- **用户登录、协作、数据库、默认公网部署**——本作品是 Windows 本机应用；公网演示为可选加分项，本报告记录决定与所需条件（见 6.4），本次不提供。
- **CSV / 手填来源、MCP 协议集成**——未实现。
- **Responses 协议下的工具循环在线验证**——只有替身测试；在线验证使用 Anthropic Messages 协议。

1.5 一句话结论

在**这张图 + 这几条可核查的官方材料**的范围内，应用能给出带引用的分部位结论，能明确说出「哪一部分现在推不出来、缺什么才能继续」， 并且把模型能做的（读图、语义匹配、措辞提议）和必须由程序做的（计算、口径适配、引用校验、改写把关）分开—— 这套分工有 20 题 ×2 臂 ×3 次的真实模型配对评测记录在案（详见第六章与第七章）。

> **本章证据出处：**能力清单与状态见 `README.md`「当前能力状态」表与 `docs/PHASES.md`；未实现项与阻塞状态见 `.scratch/stage-5-stability-submission/issues/`。

二、需求分析

2.1 用户故事到能力的映射

下表把项目各阶段写定的用户故事收敛成能力项，并给出验收状态。本地 = 有自动化测试；在线 = 有真实模型运行记录；未验证 = 只有计划或替身。

用户需求（引项目任务书）	实现方式	验收方式	状态
读者想在保存错误的模型接口地址时立即看懂哪里填错	保存时拒绝完整端点路径（`/responses`、`/chat/completions` 等），提示填写根地址，且不改动原设置	API 行为测试 + 三种视口浏览器走查	本地
读者想在模型不可用或输出无效时看到真实错误和下一步操作	未配置 / 连接失败 / 超时 / 结构不符 / 格式不支持分类提示；失败不展示任何结论	API 替身测试 + e2e「上游失败或超时只显示失败原因」	本地 在线（阶段四评测中出现过真实失败与降级）
读者想在缺数字、缺证据或跨图口径不合时看到待确认	图内检查在数值、单位、时间顺序、文字依据不全时降级「需要确认」；跨图四要素（指标 / 时间 / 单位 / 范围）任一不齐只能「待核对」	共享规则单测 + 固定样例离线评测 23/23	本地
评审想看见图片输入、模型观察、人工确认、确定性计算和证据如何接续	每条观察标出来源（模型读取 / 预置示例 / 用户更正 / 暂不可读）；确认后由程序计算并给出公式	e2e 三视口断言 + 独立 UI 评审 9/10	本地 在线（阶段一三张自制 PNG 真实读取）
读者想核对配文与公开来源是否一致，并知道依据	固定资料库 + 四个受限工具的多轮调查；引用逐条校验角色与口径，结论给到分部位状态	20 题 ×2 臂 ×3 次真实模型配对评测	在线
读者想在被指出问题后拿到可用的修改建议	逐处改动关联原句、建议、理由与当前有效引用；模型提议逐条过校验；采用与否由用户决定	整组评测中的建议规则 + e2e 采用/撤回用例	在线（生成与校验） 本地（页面采用与撤回）
团队成员想在新 Windows 环境按 README 安装并启动	根目录 `npm install` + `npm run dev`；无数据库、Docker、WSL 依赖	README 安装步骤 + CI（windows-latest，Node 24）	本地 第二台机器验收待任务 05 执行
评审想获得可访问的仓库、技术 PDF 与演示视频	README 材料索引、本报告、演示脚本与走查清单	本报告第六章与访问检查记录	材料就绪 视频录制与仓库公开待人工

2.2 需求上的取舍

取舍	理由
不做开放网络检索，改做「构建期固定的三条官方材料」	开放网络检索无法保证「引用的材料确实存在、口径确实匹配、摘录没有被改动」这三件事；固定资料库带内容指纹与口径字段，能让「引用不在本次命中内」「口径不适配」成为**可判定的程序规则**而不是模型的自觉。范围换来了可验证性。
不做自动改写配文，只给建议并要求用户点击「采用」	配文是用户的内容。程序只提议、逐处留痕、用户决定，避免「AI 悄悄改了你说的话」。
结论词汇限定为「与来源一致 / 不一致 / 待核对 / 推断依据不足 / 不支持核验」	这五个词都是**关于「与所引发布是否一致」**的表述，不表达真假与动机；术语类主张因此只能到「待核对 / 依据不足」，这是有意保留的能力边界。
不引入数据库与前端状态管理库	单机会话型应用，审计状态只存在于当前会话内存；减少依赖面与部署面，符合「Windows 根目录 Node/npm 可运行」的约束。

2.3 验收口径

项目自始至终使用同一条纪律：**计划、实现、验收是三种状态。**任务书里未勾选的项不得写进能力声明；真实模型结果、替身测试与预置样例分别计数；失败运行单列、不进分母、不删题。这条纪律本身也是作品的一部分（见第八章第 4 条创

新点）。

> **本章证据出处：**`.scratch/stage-5-stability-submission/spec.md` 的用户故事与实现决定；`docs/PHASES.md` 的阶段完成定义与逐条验收记录。

三、系统架构设计

3.1 技术选型

层	选型	理由
前端	Vue 3 + Vue Router + Vite + TypeScript	四个页面、一个工作台，组件数量不大；Vue 的单文件组件让「观察卡 / 结论卡 / 建议卡」这类结构重复、内容差异大的界面更好维护。Vite 提供秒级启动，便于「打开就能演示」。
服务端	Node + Express 5 + TypeScript（tsx 运行）	与前端同语言、同类型定义，模型适配器与领域层可以共享类型；只需一个 `npm install` 即可在 Windows 上跑起来。
领域层	纯 TypeScript（`shared/`），零运行时依赖	计算、判定、引用校验、建议校验全部是可单测的纯函数，看不到任何模型协议与 HTTP。
模型接入	OpenAI Responses 兼容 + Anthropic Messages 两种协议各一个适配器	避免被单一提供方锁死：设置页按协议分别保存地址、模型与密钥，在线验证用的是 DeepSeek 官方 Anthropic 端点。
存储	无数据库；设置写入当前 Windows 用户的 LocalAppData，审计状态只在会话内存	密钥不进仓库、不回传页面；会话数据刷新即清空，符合读者一次性核对的用法。

3.2 分层与数据流

三层结构：页面（`web/`）— 服务端（`server/`）— 领域层（`shared/`）。源码约 11 800 行 TypeScript / Vue（含样式），测试与端到端用例约 8 800 行。

目录	职责
`web/pages/`	着陆页、审计工作台、来源核验、模型设置四个页面；来源核验页把「输入 → 结论 → 建议 → 证据 → 轨迹 → 未解决项」按复查顺序排列。
`server/app.ts`	HTTP 入口与端点；只监听 `127.0.0.1`。定义 `VisionAdapter` 与 `SourceInvestigationDriver` 两个窄接口。
`server/source-investigation.ts`	受限工具循环编排器：预算、轮次、工具参数校验、轨迹记录、补证恢复、建议生成。
`shared/source-audit.ts`	引用与结论校验、口径适配、原句追溯、主张分类、建议生成与逐处校验（约 2 200 行的纯逻辑）。
`shared/source-library.ts`	固定资料库：五条材料的原始链接、发布机构、发布日期、适用口径、逐句摘录与内容指纹；多月份发布的逐行月份，以及带官方修订声明的发布所记的声明原句、修订日期与被修订发布。
`scripts/`	离线固定样例评测、在线配对评测入口、SVG→PNG 同源核对。

3.3 两个窄接口

VisionAdapter（图片读取）：Responses 用严格 JSON Schema，Messages 用强制工具调用；输入一张图，输出结构化观察值。 **SourceInvestigationDriver**（来源调查）：输入图片与配文，输出工具调用序列与最终汇总，支持沿同一会话恢复。 两个接口的共同点是**领域层与页面都看不到协议差异**——换端点、换协议不改判定逻辑，这是后续能用同一套评测同时覆盖两种协议的前提。

3.4 数据与隐私边界

数据	存放位置	说明
模型 API Key	当前 Windows 用户的 `%LOCALAPPDATA%\TuZheng\settings.json`	只由本机设置页提交给回环服务端；不读环境变量、不回传页面、不入仓库。读取接口只返回「是否已配置」。同一 Windows 账户下的其他进程也能读取该文件，README 已如实写明。
上传的图片	仅在请求期间驻留服务端内存	不写入项目目录；预置样例不发送到云端模型。

数据	存放位置	说明
调查记录（引用、轨迹、结论）	会话内存，服务端 30 分钟 TTL	服务端以「图片 + 配文指纹」兜底防止改输入后用旧结论（失配返回 409，过期 410）。
评测逐次记录	仓库内 `docs/evidence/*.json`	只含题号、结论、引用、工具序列与耗时，不含密钥与端点凭据。

3.5 与赛事提交要求的关系（环境变量与密钥）

赛题文档要求「API 密钥等敏感信息不得出现在公开仓库中，须通过环境变量方式配置」。本作品采用更严格的等价做法：**仓库内不存在任何密钥，也不从环境变量读取密钥**， 唯一的环境变量是可选的服务端口（`.env.example` 只有 `PORT=3001`）。密钥经本机设置页交给只监听 `127.0.0.1` 的服务端， 保存到当前用户的 LocalAppData，接口不回传。这样做的原因是：本应用是单机应用，密钥没有必要进入进程环境（环境变量会被子进程继承、也更容易被日志带走）。

> **本章证据出处：**`web/`、`server/`、`shared/` 目录结构与 `README.md` 的「技术架构」一节；密钥处理见 `README.md` 与 `AGENTS.md` 的「密钥与示例」约定。

四、AI 技术方案

4.1 选型理由：为什么是多模态模型 + 受限工具循环

- **必须是多模态。**输入是图表截图，模型要能读出「2025 年 12 月全国 CPI 同比上涨 0.8%」这样的图内原文。模型预设只收录支持图片输入的型号，避免接入纯文本模型后读图不可用。
- **必须能调用工具。**来源核验要「先检索、再比较、必要时问人」，这是多轮的、依赖中间结果的过程，单次问答无法表达「引用的是哪一条材料、用的哪个口径」。
- **必须是结构化输出。**观察值、主张、引用、建议都要能逐字段校验；两种协议都强制结构化（严格 JSON Schema / 强制工具调用），并在提供方拒绝时按实测回退（DeepSeek 思考模式拒绝强制工具调用、GLM 类模型思考不可关闭——结构化请求先试「关闭思考 + 强制工具调用」，被 400 拒绝时回退「不关思考 + 自动工具选择」）。
- **在线验证用的配置。** `Anthropic Messages 协议 + https://api.deepseek.com/anthropic/v1 + deepseek-flash`，逐张图约 1.1—1.4 秒、整次来源调查中位约 5—7 秒。这一配置写在证据记录里，评测脚本在开跑前会核对协议与模型，配置不符直接拒绝运行。

4.2 集成方式：一次来源调查里到底发生了什么

一次来源调查（investigation）的完整约束如下——这些数字是代码常量，评测脚本逐项比对后才允许开跑：

约束	取值	作用
可用工具	4 个	`search_source_library`（检索固定资料库）、`compare_values`（确定性数值比较）、`request_clarification`（请求用户确认，最多 1 次）、`report_source_finding`（汇总，出口）
每轮工具调用上限	3 次	超出的调用**不执行**，并连同原因写进轨迹（页面上显示为「未执行」的黄色条目）
单次调查调用总预算	6 次	检索、比较、追问计入；汇总为出口不计入。达到上限后保留已核验结论，并列出未完成部分
轮次上限	4 轮	防止无限循环
整体时限	150 秒	超时按上游超时分类提示，不产出结论
单次可核验主张	最多 3 条	超出部分与模型声明未展开的内容按原文列出，按出处分「配文未展开 / 图上说明」，不静默丢弃
补证恢复	与初查共享同一组预算	恢复不能把预算清零；引用与结论按本轮主张口径重新校验

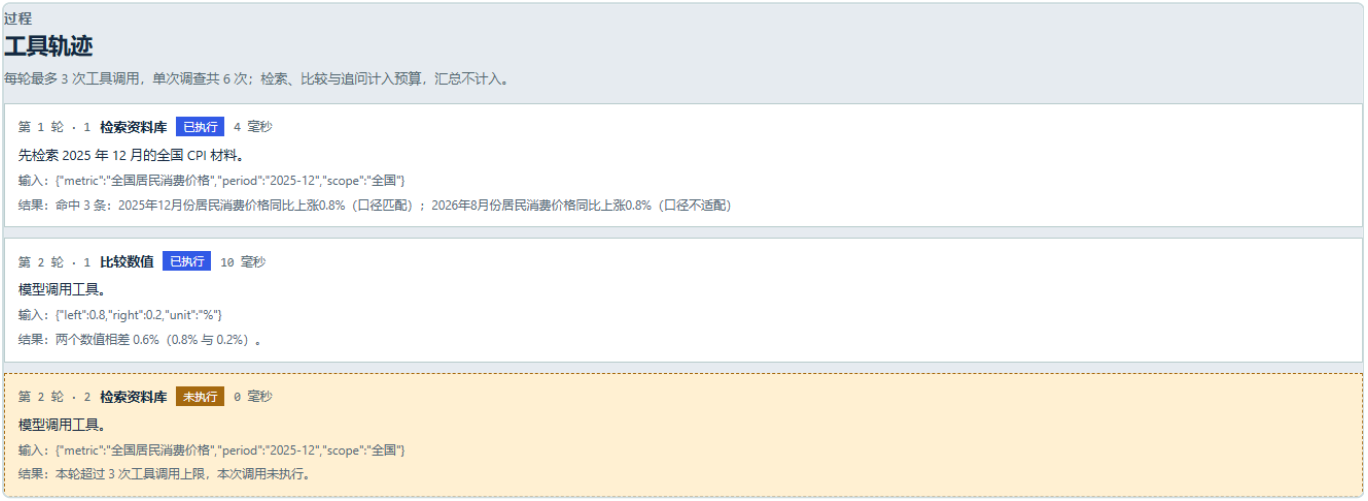


图 1　工具轨迹（替身响应渲染）。每条记录轮次、工具、执行状态、耗时、模型给出的第一句行动理由与输入 / 结果摘要。第三条是**被拒绝的调用**：同一轮超过 3 次上限，程序不执行并留档原因。

4.3 程序把关之一：引用与结论不由模型说了算

模型只能「提出引用」，能不能成立由程序按固定规则判定，规则本身可以单测：

1. **在不在本次命中内。**引用不在本次检索命中里的 ID 一律降级「来源待核对」；引用了资料库中不存在的 ID 记为**虚构引用**，引用了存在但不在本次命中内的另记「凭记忆复用」，两类分开统计。
2. **角色是否与材料类型相符。**引用一份材料时模型要声明它的角色：数值依据 / 术语解释 / 仅作背景。术语解释页只能解释「同比与环比有什么不同」，**不能为某个具体月份的数值背书。**
3. **口径是否适配（按主张判定，不按检索查询判定）。**只有指标、月份、范围都匹配的数据发布才能作为数值依据。这一条曾经按「检索时用的查询口径」判定，在真实评测里造成「模型引用了正确月份的材料却被程序拒绝」，修复后改按**这条主张自己**的指标 / 月份 / 范围判定。
4. **原句能不能追溯到出处。**配文主张必须能在配文原文里找到（文字重合度下限，且其中数字必须出现在配文或图上）；图内主张必须带图上逐字抄录，且所填比较方式要能在抄录里看到——这条规则是因为实测发现模型会给图上的数值**补一个图上没写的「同比」**，从而凭空把「待核对」变成「一致」。
5. **值对不上不等于整句成立。**推断类主张按「数字与口径」「推断结论」两个部位分别给结论；数字一致但推断方向被来源否定时，整条主张判「与来源不一致」。
6. **措辞不越权。**结论文案固定为「与所引国家统计局发布不一致」，不写「造假」「误导」，也不判断作者动机。



图 2　引用与检索命中（替身响应渲染）。命中材料带原始链接、发布机构、发布日期、摘录与内容指纹；用作数值依据的一份显示「用作数值依据」，干扰项与术语页列在「本次排除的材料及原因」中，逐条给出排除理由。

4.4 程序把关之二：修改建议由程序逐处生成与校验

核验结束后，程序按当前有效结论生成建议配文，每一步都关联证据：

主张状态	允许的改动类型	规则
与来源一致	保留原句	不得改写、不得删除（模型提议改写已核实内容会被拒）
与来源不一致	替换数值	只能用**所引来源同口径**的正确数值改正；不得保留错误数值（例如把环比 0.8% 改正为官方环比的 0.2%）
来源待核对	保留并限定 / 建议删除	必须保留限定语（如「暂未核实」）或建议删除，不得写成确定表述
推断依据不足	保留并限定 / 建议删除	同上，并说明缺哪一项依据
观点（不支持核验）	保留原句 / 建议删除	不做真假改写

模型可以在汇总里可选地附上自己的**改写提议**，但每条提议都要过一遍逐处校验：不得引入原配文、本次主张与所引来源之外的数值、月份、范围或因果 / 加强表述； 不合格的提议**连拒绝原因一起留档**，改动退回程序生成的兜底建议；提议字段本身畸形（不是数组、条目不是对象、超限）不会让整份汇总作废。



图 3　修改建议（替身响应渲染）。每处改动给出原句、建议、理由、处理方式、主张状态与当前有效引用，并标明「模型提议（已通过程序校验）」还是「程序按结论生成」；虚线框里是模型提议中被拒的一条及拒绝原因。底部按钮明确「采用这条建议（写入配文输入框）」，采用后旧结论与旧建议转入历史并要求重新核验。

4.5 优化策略

问题（实测发现）	优化	效果
模型把图上的数值补一个图上没写的比较方式	图内主张必须带图上抄录，比较方式必须写在抄录里	该规则由单测与 API 替身测试守护；真实运行中该题的漂移仍如实记录（见 7.3）
模型把检索到的官方原句当成一条配文主张	配文主张必须能在配文原文里找到（重合度下限＋数字必须出现在配文或图上）	修复后三轮评测未再出现该类错误
配文只写「12 月」，模型不去图上取年份	程序按图上标注的月份补全年份；图上没有或出现多个年份时不猜、保留原样并说明	修复后相关三题在后三轮的有检索臂 18/18 通过
模型纯文本回复导致对话里出现空 content，被上游 400 拒绝	保留文本本身；为空时不再写入空消息	整段对话不再被协议拒绝
附属列表超限（把图上说明塞进未展开项）导致整份汇总被拒，且重报指令不说明原因	上限放宽并在提示词写明「只放配文原文」；重报指令带具体字段错误摘要	汇总被拒从「整份作废」变为「可修复重报」，被拒原因写进轨迹
补证恢复时，初查以「已接收但未回应的工具调用」结束，恢复段整段被 400 拒绝	恢复前先补齐工具调用与结果的配对（含同轮被丢弃的调用）	恢复路径实测可用（有检索臂 3/3 通过）
建议里的「更强的因果表述」没有兜底	固定词表拦截因果 / 程度加强 / 中文数字范围	**边界如实保留**：未覆盖的措辞（实测出现过「略贵」）不会被拦，见 7.3

4.6 成本与可复现性

评测脚本在开跑前打印两行：本次计划发出的请求数与账户余额；支持 `--runs` / `--arms` / `--ids` / `--record` / `--strict`， 可以先跑最小档（几题 ×1 臂 ×1 次）确认配置，再决定是否跑整组。最近一次整组（20 题 ×2 臂 ×3 次＋补证恢复段＝计划 126 次请求）实耗约 1.02 元。 这一设计直接来自教训：早前的评测轮曾因提供方余额耗尽而出现大量失败，之后才加了余额预检与响应正文捕获。

> **本章证据出处：**工具与预算常量见 `server/source-investigation.ts`、`shared/source-audit.ts`；规则修复与实测见 `docs/evidence/stage-4-source-audit-evaluation-2026-09-29.md`（第 8 节）、`docs/evidence/stage-4-source-audit-claim-reasoning-2026-09-29.md`（第 6 节）、`docs/evidence/stage-4-source-audit-clarify-resume-2026-09-29.md`（第 3 节）。

五、核心功能实现

5.1 图内审计：模型只读，程序才算

「模型只读不算」是第一条产品规则：模型负责读图、提取原文与数值、做语义匹配；所有百分比、差值、单位换算和结论判定都由确定性代码完成。 读图提示词明确禁止模型给出确认值、增长率或结果状态；模型输出先经 Zod 结构校验、再由用户逐条确认，才参与判定。



图 4　审计工作台（多主张样例；界面数据来自团队预置样例与用户确认，不涉及模型）。每个观察点标出来源与状态，确认后显示程序计算的增长率与结论。

5.2 来源核验：本次主演示路径

主演示路径为「上传图文 → 主张拆解 → 工具检索 → 推断检查 → 必要补证 → 修改建议」。下面按界面顺序说明每一段做了什么、依据是什么。

（1）输入与主张拆解

上传图表截图（或载入团队自制样例）并填写配文。模型把配文拆成三类主张：**直接陈述**（原文直接写出的事实或数值）、**可检查推断**（由原文推出、原文没有直接写的结论）、**观点**（对原因、动机、价值或未来走势的判断）。观点标为「不支持核验」，系统不对它做真假结论。



图 5　来源核验的输入区（替身响应渲染）。左侧是待核验图片（团队自制示意图，图上明确标注「不是国家统计局原图」），右侧是配文与运行按钮；页面顶部说明资料库在构建期固定、运行时不访问开放网络。

（2）工具检索与逐条结论

模型在四个受限工具中自行选择：检索固定资料库、比较数值、请求用户确认、汇报结论。程序校验工具名与参数，按轮次与总量计预算，被拒绝的调用同样留在轨迹里。结论分部位给出，并逐条关联依据：



图 6　配文主张的结论卡（替身响应渲染）。展开后可见：模型拆出的指标 / 范围 / 月份 / 数值 / 比较方式、原文核对（这条主张能在配文原文里找到）、结论与依据原句、以及所引材料的角色。

版本复查：当所引发布的值已被同系列后续发布按**官方修订声明**改写时，程序改用修订后的值对照，并在结论卡上给出修订前后值、声明原句与两份发布的标题 / 日期 / 原始链接；修订关系由资料里的声明字段判定，不由模型判断（同一条规则的代码与数据见 `shared/source-library.ts` 与 `shared/source-audit.ts` 的 `applyRevision`）。

（3）必要补证：把「回答不了的问题」交给用户

当配文没写比较方式、而资料库里同比与环比的发布都在时，资料库回答不了「这句配文说的是哪个口径」——这正是必须问人的问题。 程序要求：先自己检索，检索后仍缺且会影响结论时，提出**一个**指向具体主张与具体字段的问题；反过来，资料已经覆盖的问题（配文自带口径与数值）不允许追问。 用户回答标为「用户提供」，只用于确定口径：图文没写的才填入；图文已写且与回答冲突时不覆盖、保留双方并降级为「待核对」、同时请求更正；回答解析失败不套用并说明原因。

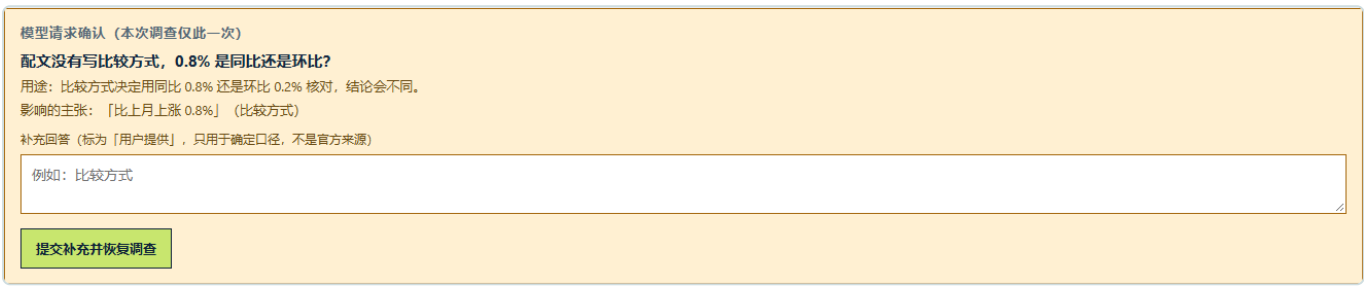


图 7　模型请求确认（替身响应渲染）。问题指明它影响哪条主张与哪项口径，并声明回答只用于确定口径、不是官方来源。

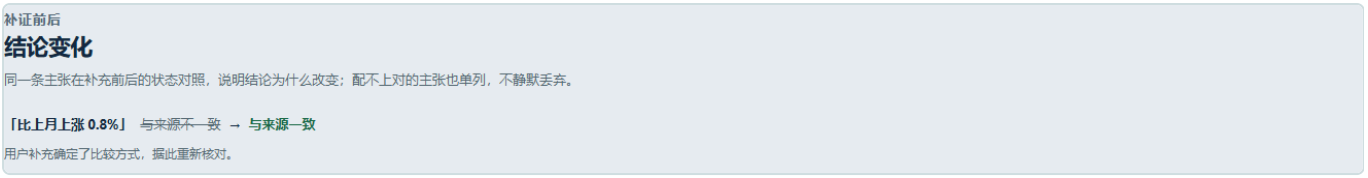


图 8　补证前后的结论对照（替身响应渲染）。沿同一条调查记录续跑，给出每条主张 before → after 与原因；配不上对的主张也单列，不静默丢弃。

（4）修改建议、采用与撤回

建议不自动替换原配文。用户点击「采用」后建议才写入配文输入框，同时旧结论与旧建议转入「历史结论（仅作历史展示）」，并要求重新核验；此后任何输入改动、重新核验或被补证结果接续，都会让旧建议立即失效并只作历史展示，历史条目保留其依据快照指纹。

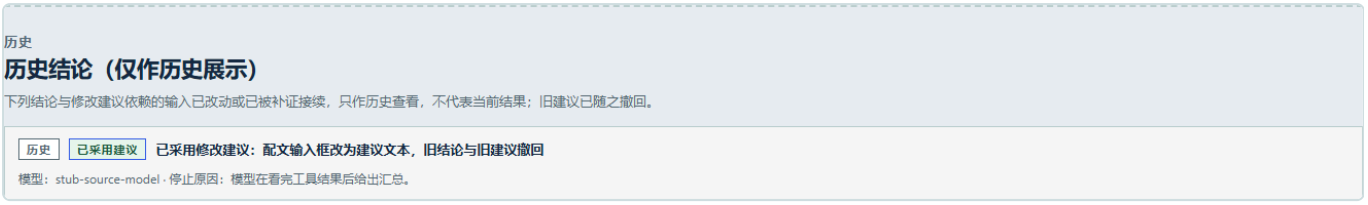


图 9　采用建议后的历史结论（替身响应渲染）。历史条目标出「已采用建议」「旧结论与旧建议撤回」「不代表当前结果」，并可展开查看当时的建议配文与依据指纹。

（5）无适用来源与证据不足时的表达

资料库没有对应月份、或推断缺少必要依据时，结论保持「来源待核对 / 推断依据不足」，并明确写出「缺哪一项才能继续」「不代表结论为假」。数据边界同时显式声明：固定资料库共五条材料（CPI 三条 + 社会消费品零售总额两条，后者是同系列发布的逐月环比修订表），干扰项与术语页会被排除并给出原因。



图 10　固定资料库清单（替身响应渲染）：材料带链接、发布机构、发布日期、适用口径与内容指纹；多月份发布显示逐月行数，带修订声明的发布标明它修订了哪一份，干扰项明确标注。

5.3 失败恢复

错误按类型区分，且失败时**不展示任何结论**（不用上一次结果或预置结果顶替）：

情形	页面表现	下一步
未配置密钥	提示「来源核验需要调用模型选择工具」，并给出直达模型设置的链接	前往设置页填写并「测试连接」（测试不保存、不发图片）
上游失败 / 超时	只显示失败原因；结果区、轨迹、停止原因都不出现	稍后重试或换用更小的图片
结构不符 / 格式不支持	分类提示；图片路径另给出框选或改用预置样例的入口	重试或改用支持格式（PNG / JPG / WebP，5 MB 上限）

情形	页面表现	下一步
建议被认为不可靠	「模型提议但未通过校验（不采用）」逐条列出提议与拒绝原因	按程序兜底建议或原句自行修改



图 11　未配置密钥时的可操作提示（替身响应渲染）。下方「展开资料库」在不配置任何模型的情况下也能查看资料库清单。

5.4 窄屏与可访问性

全部页面在 320 / 390 / 1280px 三个视口有自动化断言（含「无横向溢出」）；审计台的桌面步骤导航在窄屏收为一行当前图与步骤选择器。以下为 390px 下的结论卡。



图 12　390px 下的结论卡（替身响应渲染）。状态胶囊、原文核对与依据原句在窄屏下完整可读。

> **本章证据出处：**界面实现见 `web/pages/` 与 `web/components/`；浏览器行为断言见 `e2e/`；截图由 `e2e/submission-screenshots.mjs` 用替身响应重放生成（命令见 README）。

六、测试与部署

6.1 五层测试

层	命令	最近一次结果	覆盖与不覆盖
单元与 API 行为测试	`npm test`	338/338	计算边界、结论分级、跨图口径、纵轴风险、双协议设置与连接测试、工具循环预算与参数校验、引用与口径、主张追溯、补证解析与冲突、恢复共享预算、建议生成与逐处校验、改写提议容错解析、资料库修订关系与版本替代。不调用真实模型。
浏览器端到端	`npm run test:e2e`	90/90	30 条用例 × 320 / 390 / 1280px，含无横向溢出断言、「主图载入期间跨图区禁用并说明原因、载入失败 / 取消后恢复」与「版本复查区块展示修订前后值、官方声明原句与两份发布链接」；来源核验用例用替身响应驱动页面，真实模型结果单列在证据记录里。
离线固定评测	`npm run eval:samples`	23/23	18 张团队自制图的独立预期（观察值、增长率与公式、证据状态、轴范围、跨图待确认原因、纵轴提示）+ 5 组跨图配对；改错结论、图中文字或待确认状态会报失败。
图片同源核对	`npm run verify:sample-renders`	18/18	用 Edge 把每张 SVG 重新栅格化并与同名 PNG 逐字节比对 SHA-256，保证页面展示图与上传用图是同一份内容。
构建与类型	`npm run build`	通过	前端类型检查（vue-tsc）、服务端类型检查、Vite 打包与服务端编译。**类型检查单独成步是实测教训**：向 `shared/axis-risk.ts` 注入类型错误后 `npm test` 仍全绿（vitest 走 esbuild，只剥离类型不做检查），只有 typecheck 能拦下。

6.2 真实模型评测方法：不设「预留题」，但把口径写死

评测的目的不是产出一个漂亮分数，而是让「检索到底带来了什么」可被反驳。做法：

- **题集与期望分开冻结。**输入（图片、配文、图上声明文字、图片双指纹）在 `samples/source-audit-questions.json`，独立期望在 `samples/source-audit-expectations.json`；期望由人**先于任何模型运行**写定，不由模型生成、也不按运行结果回填。旧题的哈希有校验和守护，改写即测试失败。
- **配对对照。**同一模型、同一题集、同一资料版本下只改变检索工具可用性：无检索臂由服务端把检索工具从声明里移除，编排层同时拒绝任何检索调用（不执行检索、不回落命中），并要求模型写清缺少可用来源的原因。
- **三个维度分别报告。**事实正确性（主张状态是否正确）、证据可追溯性（接受的引用条数与角色、被拒引用及原因，无检索臂恒为 0）、不适用来源识别（干扰项与术语页的排除、越界结论次数），**不把引用能追溯当成准确率提高。**
- **允许无检索臂答对。**无检索臂给不出确定结论时，正确答案本来就是「来源待核对」——这类题目会「免费」答对，记录里逐题列出，不隐藏、也不据此宣称无检索有价值。
- **评测侧独立复算。**修改建议的「不得引入新事实」不依赖服务端校验实现，评测脚本按原始载荷独立重算一遍（数值、月份、范围、加强表述、未解决主张是否保留限定）。
- **失败运行单列。**不进分母、不删题、不用预置或缓存结果顶替；失败原因（含提供方 HTTP 402 余额耗尽）逐轮记录。

6.3 真实模型整组结果（只引用证据记录口径）

轮次	规模	有检索臂状态正确率	无检索臂 / 失败
阶段四 02	12 题 ×2 臂 ×3 次 ×3 轮 = 216 次请求，194 次产生结论	90.9% / 91.7% / 91.2%（合计 91.3%，94/103）	41.4% / 44.8% / 33.3%（合计 39.6%，36/91）；上游失败有检索 5/108、无检索 17/108
阶段四 03	17 题 ×2 臂 ×3 次 ×5 轮 = 510 次尝试	97.2% / 90.3% / 100.0% / 96.8% / 92.6%（与提交代码一致的 E 轮 92.6%，25/27）	29.7% / 32.5% / 43.5% / 36.6% / 20.8%；上游失败 25%—50%，末尾确认是提供方余额耗尽（HTTP 402）
阶段四 04	19 题整组一轮（计划 120 次请求，119 条记录）	**90.0%（54/60）**	无检索 30.5%（18/59）；上游失败 0
阶段四 05	20 题整组一轮（计划 126 次请求，124 条记录）	**93.5%（58/62）**	无检索 30.6%（19/62）；配对差 62.9 个百分点；上游失败 0
阶段四 06	22 题整组一轮（计划 138 次请求，137 条记录；题集新增 q21 / q22 两道版本修订题，资料库五条材料）	**89.7%（61/68）**	无检索 27.5%（19/69）；配对差 62.2 个百分点；上游失败 0；检索臂退化题 0；**版本复查替代生效 5 次（修正 5 / 误改 0；额外模型调用 0 次、额外轮次 0 轮）**

数据出处：`docs/evidence/stage-4-source-audit-evaluation-2026-09-29.md`、`-claim-reasoning-2026-09-29.md`、`-clarify-resume-2026-09-29.md`、`-rewrite-2026-09-30.md`、`-eval-2026-10-01-revision.md`，逐次运行记录为同目录同名 `.json`。取证不变量：虚构引用 0、无适用来源越界 0（各轮均如此）；阶段四 05 中模型 73 条改写提议里 31 条通过逐处校验被采用、42 条被拒并逐条留档；评测侧独立复算的「新事实不变量」在两臂 124 次有效运行里 0 次违规。阶段四 06 一轮里 61/68 通过、留了 7 次未通过（q06 / q16 / q18 / q20 的模型漂移，逐题写在证据记录里，不删题、不并分母）。

6.4 部署与运行

运行环境	Windows + Node.js（验收使用 Node 24.16 / npm 11.17；README 写明需 Node 22.12+ 的 22.x 或 24.x）。无数据库、Docker、WSL 依赖。
安装与启动	`npm install` → `npm run dev` → 打开 `http://127.0.0.1:5173`（API 在 `127.0.0.1:3001`）。
密钥配置	设置页选择协议（Responses / Messages）→ 填地址、模型名、Key → 保存到当前用户 LocalAppData；「测试连接」用未保存的表单参数发一条短请求，不保存、不写文件、不发图片。远程地址必须 HTTPS，回环可用 HTTP。
持续集成	`.github/workflows/ci.yml`：windows-latest + Node 24，依次跑 typecheck → build → `npm test` → `eval:samples` → `verify:sample-renders`（不阻塞）→ `test:e2e`，失败时上传 Playwright trace。CI 只跑离线路径，不配置任何模型密钥，不执行在线评测，因此不产生费用。拦截点做过人为变红验证：注入类型错误的 run 36723291466 红在 typecheck 步骤，注入断言失败的 run 36723673814 红在 `npm test` 步骤，回退后 run 36724007809 恢复绿色（链接见 README「持续集成」一节，逐次记录见 `docs/PHASES.md` 阶段五 07）。
在线演示（可选加分项）	**本次决定不提供公网演示。**原因与所需条件记录在 `docs/submission/accessibility-check.md`：本应用按设计把密钥保存在本机用户目录、服务只监听回环地址；公网演示需要另做「评审可用密钥方案」（例如平台侧代管密钥或一次性体验额度）与可用性承诺，属于独立工作项。评审请按 README 在本机启动，离线功能（样例、固定评测、三视口界面）不需要任何密钥即可运行。

> **本章证据出处：**命令与结果见 `package.json`、`.github/workflows/ci.yml`、`docs/evidence/`；本地数字由本报告提交前的收尾运行实测（六个命令，结果见附录 A）。

七、实际验证范围

这一章是评审复查的入口：每一项能力都标注它**到哪一层被验证过**，以及**没被验证的是什么。**

7.1 逐项验证状态

能力	本地测试	真实模型在线	尚未验证的部分
图内观察提取与用户确认后计算增长率	是（332 条单测 / API 测试）	是（2026-09-26，三张团队自制 PNG 经 Responses 端点，3.2—4.4 秒 / 张）	其他图表类型与端点的准确率未评估；换端点或模型后需按 STAGE-1 的五步重跑
跨图口径比对与数值冲突	是	是（2026-09-27，两张自制裁图读出 25% 对 50%，判「数值冲突」）	仅验证当前两张自制图；口径四要素的确认仍依赖用户逐项确认
柱状图纵轴风险提示	是（含 18 张固定样例的独立预期）	是（阶段三在线读数包含轴对象）	轴上限不明时柱形按示意处理，不声称精确还原
来源核验（拆主张→检索→结论）	是	是（20 题 ×2 臂 ×3 次整组一轮，有检索臂 93.5%）	题型全部是开发题、**没有预留题**，不外推准确率；只验证 `deepseek-flash` + Anthropic 协议
推断依据不足与观点不判假	是	是（同一条推断按有无适用来源分别判「依据不足 / 一致 / 不一致」）	主张分类的准确率没有单独统计
必要追问与补证恢复	是（替身覆盖解析、冲突、过期、指纹失配）	是（q18 有检索臂 3/3 先检索后追问、恢复段 3/3 通过；q19 资料已覆盖 0 次追问）	在线样本很小（补证恢复仅 5 次）；追问率有漂移（04 轮 3/3、05 轮 2/3）；会话过期与指纹失配等分支只有替身测试
修改建议的生成与逐处校验	是（26 条建议生成与校验的单测）	是（60 次运行生成建议、69 处改动；73 条提议中 31 条采用、42 条被拒留档）	「更强的因果表述」靠固定词表，实测出现的「略贵」不会被拦；月份 / 范围拦截只覆盖可解析写法
建议的采用与撤回	是（e2e 断言写入输入框、旧建议转历史）	**否**：采用是页面行为，未做真实模型下的在线复验；服	真实用户交互中的撤回体验未实测

能力	本地测试	真实模型在线	尚未验证的部分
		务端不记录用户是否采用	
失败恢复与错误分类	是（替身与 e2e；失败不展示结论；主图载入在途时跨图区禁用并说明原因，载入失败 / 取消后恢复；语义与保留边界见 `docs/adr/0001-disable-cross-picker-while-main-image-loads.md`）	部分：评测过程中出现过真实上游失败（阶段四 03 五轮 25%—50%，末尾确认 402 余额耗尽），页面与记录如实降级	真实故障下的窄屏体验、超时阈值边界未逐项复验；主图载入在途的跨图区锁定只在预置样例与 route 替身下验证，上传图的模型读取路径只有替身，无真实模型复验
Responses 协议的工具循环	是（替身）	**否**	工具循环、恢复配对与建议提议在 Responses 协议下都只有替身测试
版本修订与版本替代（同系列发布的官方修订声明）	是（单测 6 条 + e2e 1 条 ×3 视口：引用被修订的发布时按修订后值对照，并把前后值与声明原句留在结论上）	是（整组一轮 22 题 ×2 臂 ×3 次 + 恢复段：q21 写旧值 3/3 判「不一致」、q22 写修订后值 3/3 判「一致」；**版本复查替代生效 5 次，修正 5 / 误改 0，额外模型调用 0 次、额外轮次 0 轮**）	只覆盖「有官方修订声明」的修订；国家数据月度库被 WAF 拦（403），基期轮换后的月份级新旧值没核到，故未纳入
同口径冲突 → 来源存在分歧（无修订声明的同口径不同值）	未实现（无材料：`needs-info`）		不进入任何能力声明
公网在线演示	本次不提供（见 6.4）		如需提供需另记服务可用性与密钥方案

7.2 检索对照：无检索臂在哪些题上「免费答对」

无检索臂并非全错。在阶段四 05 的整组里，无检索臂 19/62 通过，其中 6 题 3/3 全对——这些题的正确答案本来就是「来源待核对」或「推断依据不足」（资料库没有适用来源、或配文没写口径）， 无检索臂无法给出确定结论，因此与期望一致。**记录逐题列出这类「免费答对」**，不把它藏起来，也不据此宣称无检索更有价值：配对差 62.9 个百分点全部来自资料库确实覆盖的那几题。 同时，**检索臂退化题 0 题**——没有出现「有检索反而比无检索差」的题目，也没有为了让无检索臂显得更差而调整题面或期望。

7.3 仍然成立的局限（逐条保留，不删题）

1. **题型是开发题，没有预留题。**四批评测的题集都由团队自制并在开发过程中扩展，不存在「先调好再考的留出题」，样本量不足以给出通用准确率。
2. **只验证了一个模型与一种在线协议。**`deepseek-flash` + Anthropic Messages；Responses 协议的工具循环只有替身测试。
3. **模型行为漂移如实记录。**q18（缺比较方式 → 应先检索再追问）：阶段四 04 有检索臂 3/3、05 为 2/3；未追问的运行判未通过且不编造恢复记录。q11 出现过模型给配文主张补了图上才有的比较方式（程序无法区分「配文写了」与

「模型补的」）。q14 一次没填推断方向、q16 两次汇总缺必填字段导致无结论。

4. **加强表述拦截有覆盖边界。**词表能拦已知的因果 / 程度加强表述与中文数字范围，但实测出现过的「略贵」这类措辞不会被识别。
5. **术语类主张只能到「待核对 / 依据不足」。**结论词汇不表达「与术语页矛盾」，这是有意的能力边界。
6. **补证恢复在线样本小**（有检索 3 次、无检索 2 次）；补证回答解析只覆盖「同比 / 环比、YYYY-MM、数值、范围 / 指标原文」这类写法。
7. **无检索臂的上游失败率曾高于有检索臂**（阶段四 02：17/108 对 5/108；03 轮末尾确认是余额耗尽）。这一不对称在样本内稳定出现但原因不能断定，只作观察记录。

> **本章证据出处：**上述每一条局限都能在对应证据记录的「不能外推、尚未验证的部分」小节找到原文；逐次运行 JSON 保留每题每次的结论、引用、工具序列与失败原因。

八、创新点

8.1 技术创新

创新点	具体做法	可核对的证据
1.「模型提议、程序把关」的受限工具循环	模型能用的只有四个工具，且工具名、参数、每轮与总量预算都由服务端逐个校验；被拒绝的调用不执行但连原因留档；最终汇总里的引用、结论与改写提议全部要过程序规则。模型只负责它擅长的：读图、语义匹配、措辞提议。	工具轨迹界面与 e2e 断言；「被拒绝调用」与「被拒提议」在整组评测里各有实测记录（阶段四 05：42 条提议被拒并逐条留档）
2. 把「口径」变成程序可判定的规则	只有指标、月份、范围都匹配的数据发布才能作数值依据；术语页只能解释比较方式；口径按**主张自己**的字段判定而不是按检索查询判定。同值干扰项（两个发布同比都是 0.8%）因此可以被程序区分。	固定资料库的干扰项设计；被拒引用逐条给出「口径不一致（月份 / 范围）」原因
3. 意图可用性的对抗性规则	三条规则直接来自实测踩坑：图内比较方式必须出现在图上抄录里（防模型凭空补口径）；配文主张必须能追溯到配文原文（防把来源原句当成用户的话）；未解决主张在建议里必须保留限定或删除（防把不确定写成确定）。	三条规则各有单测；q04、q18 等题在真实运行中的表现为「待核对 → 用户补证 → 一致」或「必须保留暂未核实」
4. 有对照、有失败、有独立复算的评测方法	有 / 无检索配对对照；期望先写、题集冻结、旧题哈希守护；允许无检索答对并逐题列出；失败运行单列不进分母；建议的「新事实不变量」由评测侧按原始载荷独立复算，不依赖服务端实现。	四批整组记录与逐次运行 JSON；阶段四 05 的两臂 124 次有效运行 0 次违反
5. 证据边界的界面表达	结论不是一句话，而是「分部位状态 + 依据原句 + 当前有效引用 + 未解决项 + 本次排除的材料及原因」；历史结论与当前结论物理分开，历史建议标明依据指纹「不代表当前结果」。	来源核验页的区块顺序与 e2e 断言；采用 / 撤回用例

8.2 应用创新

- **把「核实」拆成读者能自己复走的动作。**不是给一个「可信度 82 分」的黑箱结论，而是把过程摊开：图上写了什么、模型读到什么、你确认了什么、程序算了什么、引用了哪份材料、哪些没解决。读者可以只信自己能复查的那部分。
- **把「不知道」做成一等公民。**「来源待核对」「推断依据不足」「不支持核验」都是正式结论，界面不允许把它们写成确定表述；「本次没有核验的内容」有独立区块与覆盖度提示。
- **面向传播场景的克制。**对普通读者最危险的情形是把话说满——所以系统在缺依据时主动降级，并且在页面上说明「不能作为造假判断」。产品立场是帮助读者提问，而不是替读者定罪。

> **本章证据出处：**创新点 1—5 的实现分别见 `server/source-investigation.ts`、`shared/source-audit.ts`（引用校验、建议校验）、`scripts/evaluate-source-audit.ts`（评测侧独立复算）与 `web/pages/SourceAuditPage.vue`。

九、总结与展望

9.1 已经做到的

- 完成了一条端到端的、可在本机复现的图文来源核验路径：上传图文 → 主张拆解 → 工具检索 → 推断检查 → 必要补证 → 修改建议，并且每一段都留下可复查的记录。
- 把「模型能做什么」和「程序必须做什么」分开，并用一套可重复的评测去看这条分工是否真的有用：20 题 ×2 臂 ×3 次的整组对照里，有检索臂主张状态正确率 93.5%，无检索臂 30.6%，虚构引用与越界结论均为 0。
- 把失败与边界做成产品的一部分：错误分类提示、失败不展示结论、未解决项单列、建议只能由用户采用、旧结论立即失效并只作历史展示。
- 材料与实现对齐：本报告出现的每个数字都能指到一条命令或一份证据记录；未验收的能力（反证与版本复查、公网演示、Responses 协议工具循环）明确排除在结论之外。

9.2 做不到的（在本次提交里如实保留）

- 不能判断现实数据真伪，也不能判断作者动机；来源结论只说明「与所引发布是否一致」。
- 不能覆盖资料库之外的领域：只有 CPI 专题的三条公开材料，运行时不访问开放网络。
- 不能给出通用准确率：题集是开发题、没有预留题，样本量不支持外推。
- 不能保证模型行为稳定：追问率、主张条数、字段填写在不同运行之间有漂移，代码里能做的只是让它**可见、可判、可失败**。

9.3 下一步（按价值排序）

1. **固定库内的反证与版本复查**（需先找到经核对的同口径冲突 / 修订来源对）：这是目前最影响「可信度判断」的缺口，但必须等来源对可核对后再做，否则就是把猜测写进结论。
2. **把在线评测扩到 40—60 题并引入预留题**：现有题集把机制压测得比较充分，下一步要的是「没被调过的题」上的表现。
3. **Responses 协议的工具循环在线验证**：目前只有替身测试，补齐后「双协议」才是完整的能力而非接口形态。
4. **公网演示的密钥方案**：若决定提供在线演示，需要先定义平台侧代管密钥或一次性体验额度、限流与可用性承诺，再谈部署。
5. **建议的采用 / 撤回在真实模型下的体验复验**，以及更自然的「加强表述」识别（词表之外的措辞）。

9.4 一句话

图证想做的不是「让 AI 告诉你这张图是真的」，而是**让 AI 把可核对的依据摆到你面前，并诚实地标出它自己也不知道的地方。**

> **本章证据出处：**局限清单与下一步来源：`docs/PHASES.md` 阶段四、阶段五各节；`docs/STAGE-5-PROMPT.md` 的「未完成清单」；各证据记录的「不能外推」小节。

附录 A　证据索引

本报告只引用下表范围内的数字。所有数字在提交前由收尾运行复测，命令与结果一一对应。

A.1 本地命令（不调用真实模型）

命令	最近结果	说明
`npm test`	338/338（20 个测试文件）	单元与 API 行为测试
`npm run test:e2e`	90/90（30 用例 ×3 视口）	浏览器端到端，使用系统自带 Edge
`npm run build`	通过	含 vue-tsc 与服务端 tsc 类型检查
`npm run eval:samples`	23/23	18 张固定样例 + 5 组跨图配对
`npm run verify:sample-renders`	18/18	SVG→PNG 逐字节同源核对
`node e2e/submission-screenshots.mjs`	20 张 PNG	本报告与演示材料的界面截图（替身响应，不调用模型）

A.2 真实模型证据记录

文件	内容
`docs/evidence/stage-4-source-audit-2026-09-29.md`	阶段四 01：来源核验闭环首次在线验证（10 次运行 8 次成功）
`docs/evidence/stage-4-source-audit-evaluation-2026-09-29.md`	阶段四 02：12 题 ×2 臂 ×3 次 ×3 轮配对评测与两处程序口径修复
`docs/evidence/stage-4-source-audit-claim-reasoning-2026-09-29.md`	阶段四 03：主张分类与分部位推断结论，五轮整组
`docs/evidence/stage-4-source-audit-clarify-resume-2026-09-29.md`	阶段四 04：追问 → 补证 → 恢复，改动即失效
`docs/evidence/stage-4-source-audit-rewrite-2026-09-30.md`	阶段四 05：逐处有据的修改建议（本报告 7.1、7.2 的主要数字来源）
`docs/evidence/stage-4-source-audit-eval-2026-09-30-rewrite.json`	阶段四 05 的逐次运行记录（124 条）
`docs/evidence/stage-4-source-audit-eval-2026-10-01-revision.md`	阶段四 06：版本修订 / 版本替代的整组真实模型评测（22 题 ×2 臂 ×3 次 + 恢复段；有检索臂 89.7%，版本复查替代生效 5 次）
`docs/evidence/stage-4-source-audit-eval-2026-10-01-revision.json`	阶段四 06 的逐次运行记录（137 条）
`docs/evidence/stage-5-05-demo-path-live-2026-09-30.md`	阶段五 05：冻结演示路径的真实模型抽样（五条演示题 ×1 次检索臂，6/6）
`docs/evidence/stage-3-live-vision-2026-09-27.md`	跨图真实读取（25% 对 50%）
`docs/evidence/anthropic-provider-2026-09-28.md`	Anthropic 协议在线探测与兼容修复
`docs/evidence/stage-5-connection-test-2026-09-27.md`	「测试连接」真实点测记录
`docs/STAGE-1.md`	阶段一验收记录（含真实视觉读取五步复验）

A.3 提交材料清单

材料	位置	状态
代码仓库	`https://github.com/Iskuyal/web-match`	内容就绪；**当前为私有仓库，提交前须设为公开或为评审开通访问权限**（见 accessibility-check.md）
README（介绍、架构、安装、团队）	`README.md`	就绪，含「提交材料索引」
技术文档（PDF，≤30 页）	`docs/submission/web-match-technical-report.pdf`	就绪（源文件 `technical-report.html`，可用 `build-report.mjs` 重建）
演示视频（5—8 分钟，1080p MP4）	由团队录制后放到 README 注明的地址	**待人工录制**：脚本、分镜、演示数据与走查清单见 `docs/submission/demo-video-script.md`
环境配置说明	`.env.example`（仅 PORT） + README「Windows 快速开始」	就绪；仓库内不含任何密钥
在线演示（可选加分项）	—	本次不提供，条件记录在 `docs/submission/accessibility-check.md`

附录 B　材料纪律与敏感信息声明

B.1 真实模型、替身与预置样例分开计数

来源	用在哪里	纪律
真实模型在线	四批整组评测、连接测试、阶段一与阶段三的图片读取	记录端点协议与模型、逐次运行 JSON、耗时、失败次数与原因；只出现在 `docs/evidence/` 与第七章表格中
替身响应	全部浏览器端到端测试；本报告的界面截图；无检索臂与各种错误分支的 UI 验证	不写成模型实时结果；图表说明与图注逐张标注「替身响应渲染」
预置样例	18 张团队自制图与其独立预期；离线评测 `eval:samples`	页面标为「预置示例」；不发送到云端模型；引入新图后需同步冻结指纹

> 本作品**没有把任何动画、预置观察或替身响应当成模型的实时工具调用。**演示视频录制前要求在真机（`npm run dev`）上按走查清单把演示题实际跑通， 录制内容必须包含真实工具轨迹与一次真实失败恢复；若某题在录制时出现漂移，按清单要求如实说明或改录另一条已验收的题，不剪辑成「每次都成功」的印象。

B.2 敏感信息

- 仓库内不存在模型 API Key；被跟踪的 `.env*` 文件只有 `.env.example`（内容仅 `PORT=3001`）。
- 密钥只保存在当前 Windows 用户的 LocalAppData，经回环服务端处理；设置读取接口只返回「是否已配置」，不回传密钥；构建产物中不含密钥。
- 评测记录与截图不含密钥、不含端点凭据；截图中的界面数据均为替身响应或团队预置样例。
- 示例图片均为团队自制，图上标注「团队自制示意图，不是国家统计局原图」；引用材料使用国家统计局公开页面的链接、标题与短摘录。

B.3 图片与资料的使用许可

自制图与栅格渲染文件位于 `web/public/samples/`，其独立预期与使用许可记录在 `samples/fixed-evaluation.json`； 固定资料库引用的公开材料在 `shared/source-library.ts` 中保存原始链接、发布机构、发布日期与内容指纹， 读者可逐条打开原页面核对。